

# AI金融报告分析市场走势需求分析

## 1 需求分析

业务背景：

针对期货分析师日评文章（PDF、HTML、PNG等），构建一套自动化分析系统，实现文章读取、内容提取、数据清洗、趋势识别、大语言模型推理、结果入库及可视化展示，为市场研究人员提供统一的走势预测分析平台。

项目目标：

1. 自动读取数据库中的原始文章；
2. 支持多种文档格式解析；
3. 自动提取期货品种及走势观点；
4. 对无明确结论文章利用大语言模型推理；
5. 保存分析结果；
6. 图表展示不同品种历史预测走势。

项目角色：


项目经理1人；开发2-3人（数据处理、AI算法、后端/前端）。

## 2 整体方案

### 2.1 实现目标

建立完整的数据处理流水线，实现"数据读取→内容解析→文本清洗→趋势识别→LLM分析→结果入库→可视化展示"全流程自动化。

### 2.2 总体流程




系统流程图

## 2.3 产品架构与模块设计

系统划分为六个模块：

- ① 数据读取模块：从MySQL读取待分析文章。
- ② 文档解析模块：PDF解析、HTML解析、OCR识别图片。
- ③ 数据清洗模块：去广告、去HTML标签、统一格式、分段。
- ④ 趋势分析模块：
  - 规则引擎识别"看涨/看跌/震荡"等明确结论；
  - LLM分析隐含观点并输出预测及置信度。
- ⑤ 数据存储模块：保存文章信息、品种、预测方向、时间、来源等。
- ⑥ 数据展示模块：折线图、柱状图、品种趋势统计、时间维度分析。



模块流程图

## 2.4 界面效果

建议页面：

- 1. 首页：今日分析统计、成功率、文章数量；
  - 首页左侧：侧边栏：
    - 品种
    - 期货公司
    - 趋势分析
    - 资讯
  - 首页中间：侧边栏主页面
  - 首页右侧：搜索栏

## 3 开发设计

### 3.1 概要设计

#### 总体设计思路

系统采用**流水线（Pipeline） + 分支决策**架构风格。数据在管道中依次流过各处理节点，在"规则识别"节点处产生分支——显式预测直接入库，隐式预测走 LLM 推理路径。

优势：

- 解耦性强：每个环节职责单一，可独立开发和测试
- 效率优先：显式预测无需调用 LLM，节省成本和响应时间
- 可扩展：新增文件格式只需添加解析器，不影响其他模块

组织结构

系统按四层架构组织：


| 层级  | 核心组件              | 职责              |
|-----|-------------------|-----------------|
| 展示层 | Web 前端看板          | 预测结果可视化、筛选查询    |
| 分析层 | 规则识别引擎 + LLM 推理引擎 | 显式规则匹配、隐式观点推理   |
| 处理层 | 解析器 + 清洗器         | 多格式解析、文本清洗与编码归一 |
| 数据层 | MySQL 数据库         | 文章数据、预测结果、分析日志  |


功能模块划分

共七个核心模块：

| 模块       | 英文标识        | 职责                        |
|----------|-------------|---------------------------|
| 定时调度模块   | Scheduler   | 定时扫描数据库，获取未处理文章列表         |
| 文件解析模块   | Parser      | 根据文件类型（PDF/HTML/PNG）分发解析器 |
| 数据清洗模块   | Cleaner     | 去噪、去重、编码归一、正文抽取           |
| 规则识别模块   | RuleEngine  | 正则+关键词匹配显式预测              |
| LLM 推理模块 | LLMInfer    | 对隐式观点推理结构化结果              |
| 数据存储模块   | Repository  | 数据库读写，持久化管理               |
| 可视化模块    | WebFrontend | 看板、图表、列表展示                |

处理流程





文章表通过 `status` 字段记录处理进度：`0-未处理` → `1-解析完成` → `2-清洗完成` → `3-识别完成` → `4-推理完成` → `5-已入库` → `-1-处理失败`

模块间关系

模块之间采用**链式调用 + 状态标记**的协作模式：

| 关系              | 说明                 |
|-----------------|--------------------|
| 调度 → 解析         | 调度获取文章列表后逐条调用解析模块  |
| 解析 → 清洗         | 解析输出原始文本后调用清洗模块    |
| 清洗 → 规则识别       | 清洗后正文传入规则识别模块      |
| 规则识别 → LLM 推理   | 无显式预测的文章传递给 LLM    |
| 规则识别 / LLM → 存储 | 均将预测结果写入数据存储       |
| 存储 → 可视化        | 前端通过 API 从存储读取数据展示 |

3.2 详细设计

系统设计

采用**前后端分离架构**：

- **后端**：Python (Flask/FastAPI) + MySQL，提供 RESTful API
- **前端**：Vue.js/React 轻量框架，通过 JSON 与后端通信
- **任务调度**：APScheduler / Crontab 定时触发

子系统划分

| 子系统     | 包含模块                   | 数据边界              |
|---------|------------------------|-------------------|
| 数据处理子系统 | Parser + Cleaner       | 原始文件 → 清洗后文本      |
| 智能分析子系统 | RuleEngine + LLMInfer  | 清洗后文本 → 预测结果 JSON |
| 数据管理子系统 | Repository + Scheduler | 提供 DAO 和调度服务      |
| 展示交互子系统 | WebFrontend + API      | 数据库查询 → 页面渲染      |

功能模块详细设计

1. 定时调度模块（Scheduler）

- **输入：**无（时间触发）
- **输出：**待处理文章 ID 列表
- **流程：**
  - a. 每 5 分钟触发一次
  - b. 查询 `articles WHERE status = 0`
  - c. 按录入时间升序取前 N 条（如 20 条）
  - d. 传入解析模块
  - e. 记录扫描日志
- **状态转换：** `空闲 → 扫描 → 有命中 → 触发管道 → 等待下一周期` / `无命中 → 空闲`

2. 文件解析模块（Parser）

- **输入：**文章文件（PDF/HTML/PNG）
- **输出：**原始文本
- **流程：**
  - a. 判断文件类型（扩展名 + MIME）
  - b. **PDF** → PyMuPDF 按页读取、拼接文本
  - c. **HTML** → BeautifulSoup 解析 DOM，移除 `<script>` / `<style>`，提取 `<body>` 文本
  - d. **PNG/图片** → OCR（PaddleOCR/Tesseract）识别文字
  - e. 表格（table）→ 表格抽取，转成markdown格式+自然语言描述形式
  - f. 更新文章状态
- **状态转换：** `待解析 → 解析中 → 成功 → 转入清洗` / `失败 → 标记 -1`

### 3. 数据清洗模块 (Cleaner)

- **输入：** 原始文本
- **输出：** 清洗后纯文本
- **流程：**
  - a. 编码检测 (chardet) ，统一转 UTF-8
  - b. 噪声行过滤：匹配预设模式 ("版权所有""免责声明"等) 移除
  - c. 空白规范化：连续空白符缩并为单个
  - d. 正文提取：基于文本密度算法，提取最可能的正文块
  - e. 记录清洗前后文本长度

### 4. 规则识别模块 (RuleEngine)

- **输入：** 清洗后文本
- **输出：** 结构化预测结果 或 "需 LLM 推理" 标记
- **流程：**
  - a. **品种识别：** 遍历品种关键词词典，取最高频品种
  - b. **方向识别：** 正则匹配 ("预计.\*上涨"=看涨、"预计.\*下跌"=看跌) ，无匹配=中性
  - c. **理由提取：** 取方向关键词前后各 2 句上下文
  - d. **置信度评估：** 确定性词汇加分 ("大概率""确定") ，模糊词汇减分 ("可能""或许")
  - e. 置信度  $\geq$  阈值 (0.7)  $\rightarrow$  直接入库； $<$  阈值  $\rightarrow$  标记 "需 LLM 推理"
- **状态转换：** 规则识别  $\rightarrow$  置信度 $\geq$ 阈值  $\rightarrow$  直接入库 / 置信度 $<$ 阈值  $\rightarrow$  转入LLM推理

### 5. LLM 推理模块 (LLMInfer)

- **输入：** 清洗后文本 + 上下文 (标题、来源)
- **输出：** `{"product": "品种", "direction": "看涨/看跌/中性", "reason": "理由", "confidence": 0.0~1.0}`
- **流程：**
  - a. 构造 Prompt：设定系统角色为 "资深期货分析师"
  - b. 指定输出为 JSON 格式
  - c. 调用大语言模型 API
  - d. 解析返回 JSON，校验完整性
  - e. 置信度  $< 0.5 \rightarrow$  标记 "待人工确认"
  - f. 记录推理来源和耗时

**Prompt 模板：**

代码块

- 1
- 【系统角色】你是一位资深的期货市场分析师，擅长从分析师日评文章中提取品种走势预测。
- 2
- 【任务】判断以下文章对哪个期货品种的后续走势做了预测，并给出方向和理由。
- 3
- 【输出格式】JSON: {"product":"","direction":"看涨/看跌/中性","reason":"","confidence":0.0~1.0}
- 4
- 【正文】
- 5
- {cleaned\_text}

6. 数据存储模块（Repository）

核心 DAO 接口：

| 接口                              | 功能        |
|---------------------------------|-----------|
| getUnprocessedArticles(limit)   | 获取未处理文章   |
| updateArticleStatus(id, status) | 更新处理状态    |
| savePrediction(prediction)      | 保存预测结果    |
| getPredictions(filter)          | 按条件查询预测结果 |
| getArticleById(id)              | 获取文章详情    |

7. 可视化展示模块（WebFrontend）

API 接口：

| 接口                                | 用途   | 说明               |
|-----------------------------------|------|------------------|
| GET /api/predictions              | 预测列表 | 支持品种/时间/分析师/方向筛选 |
| GET /api/predictions/stats        | 统计数据 | 品种分布、每日分析数量汇总    |
| GET /api/articles/{id}            | 文章详情 | 原文、清洗文本、预测结果     |
| PUT /api/predictions/{id}/confirm | 人工确认 | 修正预测结果           |

8. 界面详细设计





交互要点：

- 首页支持按**品种**、**期货公司**、**预测方向**、**时间范围**四维度筛选
- 趋势图支持点击品种标签切换
- 支持手动刷新 + 自动轮询（每 30 秒）
- 文章列表行点击 → 跳转详情页
- 置信度 < 50% 的结果高亮标记"待人工确认"

3.3 开发周期

| 阶段   | 负责人  | 周期 | 输出    |
|------|------|----|-------|
| 需求分析 | 项目经理 | 2天 | 需求文档  |
| 系统设计 | 全体   | 2天 | 设计文档  |
| 数据解析 | 成员A  | 2天 | 解析模块  |
| AI分析 | 成员B  | 3天 | LLM模块 |
| 后端接口 | 成员C  | 2天 | API   |
| 前端展示 | 成员A  | 2天 | 可视化   |

|      |    |    |      |
|------|----|----|------|
| 联调测试 | 全体 | 3天 | 测试报告 |
|------|----|----|------|

## 4 非功能性需求

- 性能：支持批量分析；支持并发任务。
- 安全：数据库权限控制、日志审计。
- 可靠性：异常重试、任务状态记录。
- 兼容性：支持PDF、HTML、PNG等格式。

## 5 后续跟踪

- 后续可增加：
1. 多模型投票分析；
  2. 趋势预测准确率评估；
  3. 分析师画像；
  4. 自动日报生成；
  5. 市场风险预警。